

RELATÓRIO DE DESENVOLVIMENTO: Web Scraping - Versão Intermediária

ALUNO: Willian Nunes dos Santos

DISCIPLINA: Business Intelligence

1. INTRODUÇÃO E OBJETIVO

O objetivo deste projeto mantém a premissa de extrair dados de livros (títulos e preços) do site simulado Books to Scrape. A diferença fundamental desta versão é a adição de um tratamento específico na exportação para garantir a formatação correta em planilhas do Excel no padrão brasileiro. **Website Alvo:** Books to Scrape. **Justificativa:** Prover uma base sólida de extração HTML, aliada a boas práticas de formatação de saída de dados para o usuário final de negócios.

2. ANÁLISE DA ESTRUTURA HTML

A estrutura alvo permanece a mesma:

- **Container do Produto:** <article class='product_pod'>.
- **Título:** <h3> -> <a>[title].
- **Preço:** <p class='price_color'>.

3. FERRAMENTAS E BIBLIOTECAS UTILIZADAS

- **Python 3:** Linguagem base.
- **Requests:** Requisições HTTP.
- **BeautifulSoup (bs4):** Parsing de HTML.
- **Pandas:** Manipulação e exportação de DataFrames.

4. ALGORITMO DE EXTRAÇÃO

A lógica de navegação e parsing obedece ao mesmo fluxo: requisição na URL base, conversão em objeto soup, iteração na lista de artigos e alimentação do dicionário de dados. A grande alteração encontra-se na etapa final de exportação do DataFrame.

5. RESULTADOS E DESAFIOS

- **Formato de saída:** Arquivo relatorio_livros_toscape.csv.
- **Desafios enfrentados:** O Excel no Brasil, por padrão, utiliza ponto e vírgula (;) como separador de colunas em arquivos CSV. O uso do separador padrão (vírgula) faz com que todos os dados fiquem aglutinados em uma única coluna. A solução aplicada foi forçar o parâmetro sep=';' durante o método .to_csv() da biblioteca Pandas, garantindo que o arquivo final abrisse com as colunas certinhas.

6. CÓDIGO FONTE

Python

Importar as bibliotecas necessárias

import pandas as pd

import requests

from bs4 import BeautifulSoup

#-----

Corpo principal da aplicação

#-----

Endereço onde iremos buscar os dados a serem 'raspados'

url = 'http://books.toscrape.com/'

Executar a chamada ao endereço carregado na variavel url, carregando o resultado para a variavel pagina

pagina = requests.get(url)

Traduzir o conteudo de 'pagina' para o formato html

soup = BeautifulSoup(pagina.content, 'html.parser')

```
# Filtro do html separando efetivamente os blocos de produtos
lista_produtos_html = soup.find_all('article', class_='product_pod')

# Criar uma lista vazia para guardar nossos dados
dados_extraidos = []

# Varrer cada item encontrado para tirar Título e Preço
for produto in lista_produtos_html:
    # Pegar o titulo
    titulo = produto.find('h3').find('a')['title']

    # Pegar o preço
    preco = produto.find('p', class_='price_color').text

    # Adicionar na nossa lista
    dados_extraidos.append({
        'Nome do Livro': titulo,
        'Preço': preco
    })

#-----

# Tecnologia: Transformar a lista de dados para um dataframe, usando a biblioteca
de pandas

dataframe = pd.DataFrame(dados_extraidos)

# Salva a tabela do dataframe em uma planilha excel

# O parâmetro sep=';' garante a formatação correta para o Excel brasileiro
```

```
dataframe.to_csv('relatorio_livros_toscrape.csv', index=False, encoding='utf-8-sig',  
sep=';')
```

```
print("Arquivo gerado com sucesso!")
```

7. OBSERVAÇÕES

A adição do separador correto demonstra uma preocupação com o usuário final e a viabilidade do uso dos dados extraídos no dia a dia corporativo.